

NTNU Data Visualization with Python

氣候降尺度資料十題分析方法與結果詳解

Student ID : 61547029S

這份作業的核心問題

這份作業不是只要求把圖畫出來，而是要從四個方向評估氣候降尺度模型：

數值分布是否正確	→	預測誤差有多大
ensemble 是否有幫助	→	時間、空間與不確定性是否合理

Q1-Q4 比較數值分布；Q5-Q7 分析預測誤差；Q8 檢查不確定性；Q9-Q10 分析降雨誤差的空間分布。

十題之間的邏輯關係

```

Q1-Q4 : Prediction/Input 與 Truth 的分布是否相似
      ↓
Q5 : 每天的MAE 通常是多少
      ↓
Q6 : 增加ensemble members 是否能降低MAE
      ↓
Q7 : MAE 與CRPS 是否有月份或季節性
      ↓
Q8 : ensemble spread 能否涵蓋Ground Truth
      ↓
Q9-Q10 : 誤差在空間上出現在哪裡
  
```

Contents

1	資料結構、符號與共同前處理	4
1.1	三組資料代表什麼？	4
1.2	資料維度	4
1.3	為什麼所有題目都只分析陸地？	4
1.4	整份Notebook 的共同資料流	4
2	Q1：模型輸出降雨的分布是否接近真實降雨？	5
2.1	這題想知道什麼？	5
2.2	資料如何整理？	5
2.3	為什麼使用normalized histogram？	5
2.4	為什麼Y 軸使用log scale？	6
3	Q2：模型輸入降雨的分布是否接近真實降雨？	6
3.1	這題與Q1 有什麼不同？	6
3.2	資料處理	6

3.3	為什麼必須使用共同bins?	6
4	Q3: 模型輸出溫度的分布是否接近真實溫度?	7
4.1	分析目的	7
4.2	資料處理	7
4.3	為什麼溫度圖不需要log Y 軸?	7
5	Q4: 模型輸入溫度的分布是否接近真實溫度?	7
5.1	分析目的	7
5.2	資料處理	7
6	Q5: 溫度與降雨的每日MAE 分布為何?	8
6.1	MAE 的意義	8
6.2	第一步: 計算ensemble mean	8
6.3	第二步: 計算每個格點的absolute error	8
6.4	第三步: 得到365 個Daily MAE	9
6.5	如何解讀histogram?	9
7	Q6: 增加ensemble members 是否能改善平均準確度?	9
7.1	分析問題	9
7.2	前N 個members 的ensemble mean	9
7.3	為什麼使用cumulative sum?	10
7.4	四個子圖為什麼分開畫?	10
8	Q7: 誤差是否具有月份或季節性? MAE 與CRPS 是否不同?	10
8.1	第一步: 把時間轉成月份	10
8.2	每日MAE	11
8.3	CRPS 是什麼?	11
8.4	程式為什麼先排序?	11
8.5	如何得到月平均?	11
9	Q8: 3-sigma uncertainty range 能否涵蓋Ground Truth?	12
9.1	這題在檢查什麼?	12
9.2	計算ensemble mean 與standard deviation	12
9.3	建立3-sigma interval	12
9.4	Coverage rate	12
10	Q9: 不同月份的高降雨誤差空間分布是否不同?	13
10.1	為什麼前面的指標還不夠?	13
10.2	計算每日空間absolute error	13
10.3	計算每個月份的spatial MAE map	13
10.4	為什麼12 張圖必須共用色階?	14
11	Q10: 只看Top 10% 強降雨事件時, 空間誤差是否不同?	14
11.1	Q10 與Q9 的核心差別	14

11.2 如何定義Top 10%？	14
11.3 為什麼需要event count？	15
11.4 圖上的白色區域代表什麼？	15
12 十題的分析尺度總整理	15
13 整體科學結論	16
14 報告或口頭詢問時的重點回答	17
15 重現分析時需要的檔案與注意事項	17

1 資料結構、符號與共同前處理

1.1 三組資料代表什麼？

主NetCDF 檔案包含三個群組：

群組	意義
truth	高解析度Ground Truth，是評估模型時使用的真實參考答案。
prediction	深度學習降尺度模型的輸出；每一天有64 個ensemble members。
input	輸入模型的低品質資料。雖然已被內插成 208×208 ，但細節與極端值仍可能不足。

四個主要模型輸出變數為：

- precipitation：降雨量，單位為mm/day；
- temperature at 2m：2 公尺溫度，單位為K；
- eastward wind at 10m：10 公尺東向風，單位為m/s；
- northward wind at 10m：10 公尺北向風，單位為m/s。

1.2 資料維度

Ground Truth 與Input 可概念化為：

$$y \in \mathbb{R}^{365 \times 208 \times 208}.$$

第一個維度是日期，後兩個維度是空間位置。

Prediction 則包含64 個ensemble members：

$$x \in \mathbb{R}^{64 \times 365 \times 208 \times 208}.$$

其維度順序為：

ensemble $\times$ time $\times$ latitude grid $\times$ longitude grid.

1.3 為什麼所有題目都只分析陸地？

Land mask 中：


$$L_i = \begin{cases} 1, & \text{格點 } i \text{ 是陸地,} \\ 0, & \text{格點 } i \text{ 是海洋.} \end{cases}$$

程式使用：

```
land_mask = mask_dataset.variables['LANDMASK'][:]
land_only = land_mask == 1
```

之後所有統計量都只在 $L_i = 1$ 的位置計算。這是因為題目明確要求只使用land area；若把海洋一起納入，樣本組成與誤差大小都可能改變。

1.4 整份Notebook 的共同資料流



2 Q1：模型輸出降雨的分布是否接近真實降雨？

2.1 這題想知道什麼？

這題比較模型輸出的precipitation 與Ground Truth precipitation，目的是判斷模型是否能重現全年陸地降雨的整體數值分布。

這裡問的是邊際分布是否相似，不是問某一天、某個位置是否預測正確。即使兩組histogram 很像，仍可能存在位置錯置或日期錯置。

2.2 資料如何整理？

Ground Truth 的形狀爲：

$(365, 208, 208),$

Prediction 的形狀爲：

$(64, 365, 208, 208).$

套用land mask 後，程式將日期、空間及ensemble 維度攤平成一維：

```
truth_land_only = truth_precip[..., land_only].flatten()
pred_land_only = pred_precip[..., land_only].flatten()
```

若陸地格點數為 N_L ，則Ground Truth 約有 $365N_L$ 筆樣本，Prediction 約有 $64 \times 365N_L$ 筆樣本。

2.3 爲什麼使用normalized histogram?

因為Prediction 的樣本數是Ground Truth 的64 倍，不能直接比較每個bin 的筆數。程式使用：

```
plt.hist(..., density=True)
```

使histogram 的總面積為1，因而比較的是機率密度而不是原始筆數。

若第 b 個bin 的寬度為 Δ_b 、樣本比例為 p_b ，其density 可理解為：

$$h_b = \frac{p_b}{\Delta_b}.$$

2.4 為什麼Y 軸使用log scale？

降雨分布高度右偏：無雨或弱降雨非常多，極端降雨非常少。如果使用一般線性Y 軸，高降雨尾端會被大量低降雨樣本掩蓋。

```
plt.yscale('log')
```

log scale 能同時顯示高密度的弱降雨區間與低密度的極端降雨尾端。

Q1 圖表證據與結論

Prediction 與Ground Truth 在低至中等降雨量區間有高度重疊，表示模型大致掌握一般降雨的整體分布。

但是Ground Truth 的右尾延伸得更遠，而Prediction 在高降雨量區間下降得較快，代表模型低估部分極端降雨。此外，Prediction 出現少量小於0 的降雨值；負降雨在物理上不合理，顯示輸出仍可能需要非負約束或後處理。

Q1 能回答與不能回答的事

這張圖能回答「全年所有陸地值的整體分布是否相似」，但不能證明模型在正確日期、正確位置預測出正確降雨。位置與時間配對誤差要由後面的MAE、月份分析與空間圖判斷。

3 Q2：模型輸入降雨的分布是否接近真實降雨？

3.1 這題與Q1 有什麼不同？

Q1 比較模型Prediction 與Truth；Q2 比較模型Input 與Truth。其目的在於檢查低品質內插輸入本身與高解析Ground Truth 有多大差異，也可與Q1 對照，判斷模型輸出是否比原始輸入更接近真實資料。

3.2 資料處理

```
truth_precip = dataset.groups['truth'].variables['precipitation'][:]
input_precip = dataset.groups['input'].variables['precipitation'][:]

truth_land_only = truth_precip[..., land_mask == 1].flatten()
input_land_only = input_precip[..., land_mask == 1].flatten()
```

Input 沒有64 個ensemble members，因此兩組資料都只包含日期與空間維度。後續同樣使用共同bins、density=True 與log Y 軸。

3.3 為什麼必須使用共同bins？

如果兩個histogram 各自使用不同範圍與切分方式，即使視覺上重疊，也不能公平比較。程式先找出共同最小值與最大值：

```
hist_min = min(np.min(truth_land_only), np.min(input_land_only))
hist_max = max(np.max(truth_land_only), np.max(input_land_only))
shared_bins = np.linspace(hist_min, hist_max, 51)
```

因此每一個柱子都代表相同的降雨量區間。

Q2 圖表證據與結論

Input 與Ground Truth 在低降雨量區間大致相近，但Input 的高降雨右尾明顯較短，在中高降雨量區間的密度也較低。

這代表低解析資料經過一般內插後，雖然尺寸已變成 208×208 ，仍無法恢復真正高解析資料中的

強降雨與極端值。內插會讓資料變得平滑，但不會自動創造缺失的小尺度強降雨結構。

Q1 與Q2 合併解讀

Q2 顯示Input 對高降雨的表示不足；Q1 顯示Prediction 雖仍低估最極端尾端，但通常比Input 更能延伸到中高降雨區間。因此模型確實學到了一部分原始輸入沒有的降雨結構。

4 Q3：模型輸出溫度的分布是否接近真實溫度？

4.1 分析目的

這題將模型輸出的2m temperature 與Ground Truth 2m temperature 比較，檢查模型能否重現全年陸地溫度的整體數值範圍與分布形狀。

4.2 資料處理

```
truth_temp = dataset.groups['truth'].variables['temperature_2m'][:]  
pred_temp = dataset.groups['prediction'].variables['temperature_2m'][:]  
  
truth_land_only = truth_temp[..., land_mask == 1].flatten()  
pred_land_only = pred_temp[..., land_mask == 1].flatten()
```

和Q1 一樣，Prediction 的64 個members 全部納入分布分析。使用density=True 後，樣本數差異不會主導圖形。

4.3 為什麼溫度圖不需要log Y 軸？

降雨通常有大量接近0 的資料以及很長的右尾；溫度則集中在較連續的範圍內，分布沒有降雨那麼極端偏斜。因此一般線性Y 軸已能清楚比較兩組密度。

Q3 圖表證據與結論

Prediction 與Ground Truth 的histogram 在大部分溫度區間幾乎重疊，兩者的主要溫度範圍、峰值位置與分布形狀都非常接近。
因此模型能良好重現全年溫度的整體統計特性。相較於降雨，溫度是較平滑、較連續的物理變數，所以通常也較容易被模型預測。

分布相似不等於逐點準確

假設模型把北部與南部的溫度互換，整體histogram 仍可能相同。因此Q3 只能說明全域分布相似，不能單獨證明空間與時間上的預測完全正確。逐點準確度需要用MAE 等指標檢查。

5 Q4：模型輸入溫度的分布是否接近真實溫度？

5.1 分析目的

這題比較Input temperature 與Ground Truth temperature，檢查低品質內插輸入是否保留真實資料的高低溫變化。

5.2 資料處理

```
truth_temp = dataset.groups['truth'].variables['temperature_2m'][:]
input_temp = dataset.groups['input'].variables['temperature_2m'][:]

truth_land_only = truth_temp[..., land_mask == 1].flatten()
input_land_only = input_temp[..., land_mask == 1].flatten()
```

兩組資料使用相同bins 與normalized histogram，比較的是全年所有陸地格點的溫度分布。

Q4 圖表證據與結論

Input 與Ground Truth 的主要溫度範圍有重疊，但Input 分布較窄，資料較集中在中間溫度區間；Ground Truth 則具有較完整的低溫與高溫尾端。
這代表內插輸入具有平滑效應：極低溫與極高溫容易被削弱，中間溫度的相對比例則提高。與Q3 對照後，可以看出Prediction 的分布明顯比Input 更接近Ground Truth。

Q3 與Q4 合併解讀

Q4 說明原始Input 對溫度極端值的表現不足；Q3 則顯示模型輸出幾乎重現Ground Truth 的整體溫度分布。因此模型不只是複製Input，而是修正了一部分內插造成的分布壓縮。

6 Q5：溫度與降雨的每日MAE 分布為何？

6.1 MAE 的意義

Absolute Error 是預測值與真實值差距的絕對值：

$$e_{d,i} = |\hat{y}_{d,i} - y_{d,i}|,$$

其中 d 表示日期， i 表示陸地格點。

MAE 對所有誤差給相同線性權重，單位與原變數相同，因此容易解釋：溫度MAE 的單位是K，降雨MAE 的單位是mm/day。

6.2 第一步：計算ensemble mean

每一天有 $M = 64$ 個prediction members。程式先計算ensemble mean：

$$\bar{x}_{d,i} = \frac{1}{M} \sum_{m=1}^M x_{m,d,i}.$$

```
pred_temp_mean = np.ma.mean(pred_temp, axis=0)
pred_precip_mean = np.ma.mean(pred_precip, axis=0)
```

資料形狀由(64, 365, 208, 208) 變成(365, 208, 208)。

6.3 第二步：計算每個格點的absolute error

```
temp_absolute_error = np.abs(pred_temp_mean - truth_temp)
precip_absolute_error = np.abs(pred_precip_mean - truth_precip)
```

只保留陸地後，每一天仍保有所有陸地格點的誤差。

6.4 第三步：得到365 個Daily MAE

若陸地格點集合為 $\mathcal{L}$ 、格點數為 N_L ，則第 d 天的MAE 為：

$$\text{MAE}_d = \frac{1}{N_L} \sum_{i \in \mathcal{L}} |\bar{x}_{d,i} - y_{d,i}|.$$

```
temp_daily_mae = np.ma.mean(temp_error_land, axis=1)
precip_daily_mae = np.ma.mean(precip_error_land, axis=1)
```

因此每個變數有365 個數字。Histogram 中的一筆樣本代表一天，而不是一個格點。

6.5 如何解讀histogram？

Histogram 回答的是：

一年之中，有多少天的平均陸地誤差落在某個範圍？誤差是否集中？是否有少數極端錯誤日期？

Q5 溫度結果

溫度Daily MAE 大多集中在約0.3–0.6 K，表示多數日期的平均溫度誤差相對穩定。只有少數日期超過1 K，並有極少數日期接近約2.15 K。
因此溫度MAE 分布雖然略向右偏，但整體集中度高，模型在大部分日期的溫度表現較穩定。

Q5 降雨結果

降雨Daily MAE 呈現明顯右偏：大量日期集中在低MAE 區間，但少數日期的MAE 非常高，最大可接近約70 mm/day。
這表示模型平常的降雨誤差可能不大，但在少數強降雨或極端天氣日期會出現很大的預測錯誤。只看全年平均值可能會掩蓋這種長右尾風險，因此畫出完整分布是必要的。

不同變數的MAE 數字不能直接比較

溫度與降雨的單位不同，不能因為降雨MAE 數字較大，就直接說模型對降雨一定差多少倍。合理的比較方式包括各自變數內部比較、標準化誤差，或與該變數自然變異幅度相比。

7 Q6：增加ensemble members 是否能改善平均準確度？

7.1 分析問題

這題要判斷當ensemble members 從1 個逐漸增加至64 個時，ensemble mean 的MAE 是否降低，以及四個輸出變數是否具有相同趨勢。

7.2 前 N 個members 的ensemble mean

當使用前 N 個members 時：

$$\bar{x}_{d,i}^{(N)} = \frac{1}{N} \sum_{m=1}^N x_{m,d,i}, \quad N = 1, 2, \dots, 64.$$

對應的整體陸地MAE 為：

$$\text{MAE}_v(N) = \frac{1}{365N_L} \sum_{d=1}^{365} \sum_{i \in \mathcal{L}} |\bar{x}_{d,i}^{(N)} - y_{d,i}|,$$

其中 v 代表precipitation、temperature 或wind variable。

7.3 為什麼使用cumulative sum?

若每個 N 都重新計算前 N 個members 的平均，會重複大量加法。程式先做：

```
pred_cumsum = np.ma.cumsum(pred_data, axis=0)
```

則前 N 個members 的總和已存在：

```
pred_n_mean = pred_cumsum[n - 1] / n
```

這能降低不必要的重複運算。

7.4 四個子圖為什麼分開畫?

四個變數的單位與自然尺度不同：

變數	MAE 單位
Precipitation	mm/day
Temperature 2m	K
Eastward Wind 10m	m/s
Northward Wind 10m	m/s

因此分成四張圖，觀察每個變數本身隨 N 改變的趨勢，而不是直接比較不同單位的絕對高度。

Q6 圖表證據與結論

四個變數的MAE 都隨ensemble members 增加而下降。從1 個增加至數個members 時改善最明顯；約在10–20 個members 後，曲線逐漸變平；接近64 個members 時，繼續增加members 的改善已很小。

這表示ensemble averaging 能抵消個別member 的隨機偏差或雜訊，但存在邊際效益遞減。四個變數方向一致，兩個風速變數的相對降幅較明顯，降雨的相對改善則較小。

方法上的一個重要限制

目前程式使用「前 N 個members」，因此曲線會受到ensemble 排列順序影響。若要估計一般化的ensemble-size 效果，可對每個 N 多次隨機抽取members，再報告平均MAE 與信賴範圍。不過目前方法仍能回答這組固定ensemble 順序下的累積平均效果。

8 Q7：誤差是否具有月份或季節性？MAE 與CRPS 是否不同？

8.1 第一步：把時間轉成月份

NetCDF 的時間通常不是直接儲存成日期文字，而是「從某個基準時間開始經過多少小時或天」。程式使用：

```
dates = nc.num2date(
    time_var[:],
    units=time_var.units,
    calendar=time_var.calendar
)
months = np.array([date.month for date in dates])
```

得到每一天所屬的月份 $m(d) \in \{1, \dots, 12\}$ 。

8.2 每日MAE

MAE 使用ensemble mean：

$$\bar{x}_{d,i} = \frac{1}{M} \sum_{m=1}^M x_{m,d,i},$$

$$\text{MAE}_d = \frac{1}{N_L} \sum_{i \in \mathcal{L}} |\bar{x}_{d,i} - y_{d,i}|.$$

因此MAE 評估的是ensemble mean 作為一個deterministic prediction 時的準確度。

8.3 CRPS 是什麼？

CRPS，全名Continuous Ranked Probability Score，用來評估整個ensemble predictive distribution，而不是只看ensemble mean。

對某一天、某個格點，若ensemble predictions 為 $x_1, \dots, x_M$ ，Ground Truth 為 y ，則ensemble CRPS 為：

$$\text{CRPS} = \frac{1}{M} \sum_{m=1}^M |x_m - y| - \frac{1}{2M^2} \sum_{m=1}^M \sum_{j=1}^M |x_m - x_j|.$$

第一項測量所有members 與Ground Truth 的距離；第二項反映ensemble members 彼此之間的spread。

MAE 與CRPS 的差別

MAE 只問：「64 個members 的平均預測準不準？」

CRPS 則問：「整個ensemble distribution 是否同時具有正確位置與合理spread？」

兩個指標都是越低越好，但CRPS 對probabilistic forecast 提供更完整的評估。

8.4 程式為什麼先排序？

直接計算第二項需要建立 $M \times M$ 的兩兩差異。程式將predictions 排序後，使用等價快速公式：

$$\frac{1}{M^2} \sum_{m=1}^M (2m - M - 1)x_{(m)},$$

其中 $x_{(m)}$ 是由小到大排序後的第 m 個member。

此公式與完整兩兩差異公式數學上等價，但更節省記憶體與計算量。

8.5 如何得到月平均？

先算每日MAE 與每日CRPS，再將同月份的日期平均：

$$\overline{\text{MAE}}_k = \frac{1}{D_k} \sum_{d:m(d)=k} \text{MAE}_d,$$

$$\overline{\text{CRPS}}_k = \frac{1}{D_k} \sum_{d:m(d)=k} \text{CRPS}_d,$$

其中 D_k 為第 k 個月份的天數。

Q7 降雨結果

降雨呈現最明顯的季節性。1–3 月誤差較低，4 月開始上升，6–9 月明顯較高，並在 8 月達到最高；之後於秋季下降，11 月降至低值。

MAE 與 CRPS 的月份趨勢高度相似，表示夏季的高誤差不只是 ensemble spread 的問題，ensemble mean 本身也在這些月份較難準確預測。

Q7 溫度與風速結果

溫度和兩個風速變數也會隨月份波動，但變化不像降雨那麼平滑。兩種指標的高低月份大致相互對應，例如部分變數在 5 月或 8 月較高、11 月較低。

CRPS 通常低於 MAE 的數值，但不能只依兩條線的高度判斷優劣，因為它們衡量的對象不同；更重要的是比較兩者的月份趨勢是否一致。

9 Q8 : 3-sigma uncertainty range 能否涵蓋 Ground Truth ?**9.1 這題在檢查什麼？**

64 個 ensemble members 不只可以取平均，也可用其 spread 表示模型的不確定性。若模型在某個格點的 members 非常分散，表示模型對該位置較不確定；若 members 很集中，表示模型聲稱自己較有把握。

這題要檢查模型所提供的不確定性是否足以涵蓋真實答案。

9.2 計算 ensemble mean 與 standard deviation

對每一天、每個格點：

$$\mu_{d,i} = \frac{1}{M} \sum_{m=1}^M x_{m,d,i},$$

$$\sigma_{d,i} = \sqrt{\frac{1}{M} \sum_{m=1}^M (x_{m,d,i} - \mu_{d,i})^2}.$$

目前程式使用 NumPy 預設的 population standard deviation，即 `ddof=0`。

9.3 建立 3-sigma interval

$$I_{d,i} = [\mu_{d,i} - 3\sigma_{d,i}, \mu_{d,i} + 3\sigma_{d,i}].$$

若 Ground Truth 滿足：

$$\mu_{d,i} - 3\sigma_{d,i} \leq y_{d,i} \leq \mu_{d,i} + 3\sigma_{d,i},$$

則該樣本被視為 covered。

9.4 Coverage rate

$$\text{Coverage} = \frac{\sum_{d=1}^{365} \sum_{i \in \mathcal{L}} \mathbf{1}(y_{d,i} \in I_{d,i})}{365 N_L} \times 100\%.$$

若 predictive distribution 近似常態而且校準良好， $\mu \pm 3\sigma$ 理論上約涵蓋 99.7% 的結果。這個 99.7% 是參考基準，不代表所有非高斯變數都必須精確達到該數值。

變數	3-sigma Coverage
Precipitation	約83.01%
Temperature 2m	約80.90%
Eastward Wind 10m	約85.65%
Northward Wind 10m	約89.04%

Q8 結論

四個變數的coverage 都低於90%，與常態分布下3-sigma 約99.7% 的參考值有明顯差距。因此ensemble uncertainty range 無法充分涵蓋Ground Truth。這表示ensemble spread 相對於實際預測誤差偏窄，模型可能有overconfidence。四個變數的方向一致，但程度不同：Northward Wind coverage 最高，Temperature coverage 最低。

Coverage 的正確解讀

Coverage 低不一定只代表平均預測差，也可能代表ensemble members 太集中。相反地，單純把spread 放得非常寬雖可提高coverage，卻不代表預測有用。因此完整的不確定性評估應同時考慮coverage、interval width、CRPS、rank histogram 與spread-skill relation。

10 Q9：不同月份的高降雨誤差空間分布是否不同？

10.1 為什麼前面的指標還不夠？

Q5 與Q7 將所有陸地格點平均成一個數字，因此能描述整體誤差大小，卻無法回答誤差主要發生在哪裡。

Q9 保留 208×208 空間結構，對每個格點分別計算monthly spatial MAE。

10.2 計算每日空間absolute error

先對64 個members 取平均：

$$\bar{x}_{d,i} = \frac{1}{64} \sum_{m=1}^{64} x_{m,d,i}.$$

再計算每個位置的誤差：

$$e_{d,i} = |\bar{x}_{d,i} - y_{d,i}|.$$

這一步沒有對空間格點取平均，因此每天仍保留一張 208×208 的error map。

10.3 計算每個月份的spatial MAE map

對第 k 個月份：

$$E_{k,i} = \frac{1}{D_k} \sum_{d:m(d)=k} e_{d,i}.$$

$E_{k,i}$ 表示格點 i 在第 k 個月份的平均降雨絕對誤差。最後得到12 張地圖：

$$E \in \mathbb{R}^{12 \times 208 \times 208}.$$

海洋位置被設為NaN，因此不顯示：

```
monthly_mae = np.full((208, 208), np.nan)
monthly_mae[land_only] = (
    error_sum[land_only] / len(day_indices)
)
```

10.4 為什麼12張圖必須共用色階？

如果每張圖各自設定最大值，一個低誤差月份也可能看起來和高誤差月份一樣亮。因此程式使用共同的：

```
vmin = 0
vmax = np.nanpercentile(all_land_errors, 99)
```

共同色階讓相同顏色在所有月份代表相同誤差大小。使用第99百分位作為上限，可避免極少數極端值壓縮其餘地圖的色彩差異；代價是高於該值的區域都會呈現最亮顏色。

Q9 圖表證據與結論

降雨誤差的空間分布會隨月份明顯改變。1–3月整體較暗，高誤差區域較少；4–5月開始增加；6–9月大範圍區域變亮，8月尤其明顯；10月後逐漸下降，11–12月再次較低。因此模型降雨誤差同時具有季節性與空間性。不同地區可能因地形、季風、對流降雨或資料解析度等因素，在不同月份呈現不同的預測難度。

Q7 與Q9 的關係

Q7告訴我們「哪個月份整體誤差較大」；Q9進一步告訴我們「該月份的誤差主要出現在哪些位置」。Q7是時間摘要，Q9是保留地理位置的空間診斷。

11 Q10：只看Top 10% 強降雨事件時，空間誤差是否不同？

11.1 Q10 與Q9 的核心差別

Q9使用所有日期與所有降雨強度，因此包含無雨、弱降雨與強降雨。Q10只保留Ground Truth 中最高的10%降雨值，專門檢查模型在高降雨事件下的空間誤差。

11.2 如何定義Top 10%？

程式先收集全年所有陸地日期–格點的Ground Truth precipitation：

$$\mathcal{Y}_L = \{y_{d,i} : d = 1, \dots, 365, i \in \mathcal{L}\}.$$

再計算第90百分位門檻：

$$q_{0.9} = \text{Percentile}_{90}(\mathcal{Y}_L).$$

Notebook 的執行結果為：

$$q_{0.9} \approx 12.9302 \text{ mm/day}.$$

事件指示變數為：

$$I_{d,i} = \mathbf{1}(i \in \mathcal{L})\mathbf{1}(y_{d,i} \geq q_{0.9}).$$

因此這裡的「事件」是某一天、某個陸地格點的Ground Truth precipitation 達到全年陸地資料的最高10%，不是將整個日期視為單一事件。

11.3 為什麼需要event count？

不同格點在不同月份發生強降雨的次數不同。程式分別累積：

```
error_sum[extreme_event] += abs_error[extreme_event]
event_count[extreme_event] += 1
```

對月份 k 、格點 i ，Top 10% 條件下的平均誤差為：

$$E_{k,i}^{\text{extreme}} = \frac{\sum_{d:m(d)=k} I_{d,i} |\bar{x}_{d,i} - y_{d,i}|}{\sum_{d:m(d)=k} I_{d,i}}.$$

只有分母大於0，也就是該格點在該月真的發生過強降雨時，才會計算平均值。

11.4 圖上的白色區域代表什麼？

沒有事件的格點被設為NaN：

```
has_event = event_count > 0
monthly_extreme_mae[has_event] = (
    error_sum[has_event] / event_count[has_event]
)
```

因此白色可能代表：

- 海洋格點；或
- 該陸地格點在該月份沒有發生Top 10% 強降雨。

白色不代表誤差為0。若誤把白色解讀成完美預測，會得到錯誤結論。

Q10 圖表證據與結論

只考慮Top 10% 強降雨時，不同月份的高誤差區域仍明顯不同。冬季強降雨事件較少，有效區域較零散；5–10 月強降雨事件增加，高誤差區域更廣且更集中。
相較於Q9，Q10 的色階上限與實際誤差幅度明顯較高，表示模型在極端降雨條件下比一般天氣更容易產生大誤差。這也說明只看所有事件的平均誤差，可能低估模型在重要極端事件中的風險。

Top 10% 定義的限制

目前使用全年所有陸地日期–格點的統一第90 百分位門檻。若改成「每個月份各自的Top 10%」、「每個格點各自的Top 10%」或「全年降雨量最高的10% 日期」，事件集合與結論都會不同。報告時應明確說明本題採用的是全年、全陸地、grid-day level 的統一門檻。

12 十題的分析尺度總整理

題目	主要比較	被平均或攤平的維度	最後圖表回答的問題
Q1	Prediction precip vs Truth	ensemble、time、space 攤平	模型輸出降雨的整體分布是否相似？
Q2	Input precip vs Truth	time、space 攤平	原始輸入降雨是否缺少強降雨？
Q3	Prediction temp vs Truth	ensemble、time、space 攤平	模型輸出溫度的整體分布是否相似？
Q4	Input temp vs Truth	time、space 攤平	輸入溫度是否因內插而過度平滑？

Q5	Ensemble mean vs Truth	每天對land space 平均	一年中每日MAE 的分布與極端值如何？
Q6	不同ensemble size	對time 與land space 平均	members 增加是否降低整體MAE？
Q7	月份MAE/CRPS	每天對land space 平均，再按月平均	誤差是否有月份或季節性？
Q8	$\mu \pm 3\sigma$ vs Truth	對全年所有land samples 計數	ensemble uncertainty 是否充分涵蓋真值？
Q9	Monthly precip error	保留space，對該月日期平均	一般降雨誤差主要出現在哪裡？
Q10	Top 10% precip error	保留space，只平	強降雨條件下的高誤差區域在哪裡？
		均extreme events	

13 整體科學結論

結論一：模型對溫度分布的重建優於降雨極端值

模型輸出溫度與Ground Truth 的分布幾乎重疊，表示模型能有效重現溫度的整體統計特性。降雨的一般範圍也有相似性，但模型對高降雨尾端仍有低估，並出現少量負降雨預測。

結論二：模型輸出相較於Input 有改善

Input precipitation 缺少高降雨尾端，Input temperature 則呈現較窄、較平滑的分布。Prediction 對兩者都有改善，代表模型不是單純複製內插輸入，而是學到部分高解析結構。

結論三：降雨比溫度更難預測

溫度Daily MAE 較集中；降雨Daily MAE 呈長右尾，少數日期可能出現非常大的誤差。這反映強降雨具有局部性、非線性與高度不均勻等特性。

結論四：增加ensemble members 有幫助，但效益遞減

四個變數的ensemble-mean MAE 都隨members 增加而下降，前幾個members 的改善最大，約10–20 個members 後逐漸趨平。因此ensemble averaging 有效，但不是members 越多就能等比例改善。

結論五：降雨誤差具有明顯季節與空間模式

降雨MAE 與CRPS 在夏季升高，8 月最高。空間圖也顯示6–9 月高誤差區域明顯擴大。模型困難並非均勻分布，而是與月份、地理位置及強降雨事件有關。

結論六：ensemble uncertainty 偏窄

四個變數的3-sigma coverage 約為81–89%，遠低於常態分布參考值99.7%。這代表ensemble spread 無法充分反映實際誤差，模型存在不確定性低估或overconfidence 的可能。

最終總結

此降尺度模型對一般氣候狀態，尤其是溫度，具有良好的整體分布重建能力；ensemble averaging 也能改善平均預測準確度。然而，極端降雨仍是主要弱點：模型低估高降雨尾端、極端日期的MAE 很大，而且高誤差具有明顯季節與空間差異。此外，ensemble spread 對真實誤差的涵蓋

不足，因此未來除了提升平均預測，也應改善極端事件表現與probabilistic calibration。

14 報告或口頭詢問時的重點回答

為什麼precipitation histogram 使用log Y 軸？

因為弱降雨樣本很多、極端降雨樣本很少。使用log scale 才能同時看到主要分布與低密度右尾。

為什麼Prediction 有64 倍樣本仍能 Truth 比？

因為histogram 使用density=True，比較的是正規化後的機率密度，而不是原始樣本筆數。

為什麼Q5 使用ensemble mean？

因為MAE 是deterministic prediction metric。先將64 個members 平均，可以把ensemble 轉成單一代表預測，再和Ground Truth 比較。

CRPS 為什麼比MAE 更適合ensemble？

MAE 只評估ensemble mean；CRPS 使用所有members，能同時考慮真值距離與ensemble spread，因此更適合probabilistic forecast。

Coverage 低代表什麼？

代表Ground Truth 經常落在ensemble mean $\pm 3\sigma$ 之外。可能原因是ensemble spread 太小、平均預測有偏差，或predictive distribution 並非理想常態分布。

Q9 與Q10 有何不同？

Q9 是所有天氣條件的monthly spatial MAE；Q10 是Ground Truth 達到全年Top 10% 時的conditional spatial MAE。Q10 更聚焦於高影響的強降雨事件。

Q10 的白色區域是不是零誤差？

不是。白色可能是海洋，也可能是該格點當月沒有Top 10% 強降雨事件，因此沒有可計算的conditional MAE。

15 重現分析時需要的檔案與注意事項

Notebook 使用相對路徑，因此執行時必須將下列檔案放在同一資料夾：

- 61547029s.ipynb
- output_0_all.nc
- wrf_208x208_grid_coords.nc

執行前需安裝：

```
numpy
matplotlib
netCDF4
```

由於主資料約15 GB，部分題目一次讀取全年64-member prediction 時會使用大量記憶體。Q7–Q10 採逐日讀取，可降低記憶體需求；若電腦記憶體不足，Q1、Q3、Q5、Q6 也可改成逐日或分批處理。

最後應牢記的八句話

1. Q1–Q4 比較的是整體分布，不是逐點正確性。
2. Histogram 使用共同bins 才能公平比較。
3. 降雨使用log Y 軸是爲了看見稀少的極端尾端。
4. Q5 的一筆histogram 樣本代表一天的land-average MAE。
5. Q6 顯示ensemble averaging 有效，但具有邊際效益遞減。
6. MAE 評估ensemble mean；CRPS 評估整個ensemble distribution。
7. 3-sigma coverage 低表示模型的不確定性範圍不夠寬或預測存在偏差。
8. Q9 看所有降雨，Q10 只看Ground Truth Top 10% 強降雨。